



Clustering de protéines et inférence de familles fonctionnelles

PMIND - M1 MIND

GAUTEUR Mathilde
THOMAS Elise

Mai 2026

Table des Matières

01

Introduction

02

Pipeline

03

**Première
Approche**

04

**Deuxième
Approche**

05

Conclusion

06

Ouverture


Présentation du problème

Données

01

Séquences protéiques

- environ 7,4 M
- format FASTA
- dinoflagellés



02


Annotations fonctionnelles PFAM

- 30,8 % de protéines annotées
- 2,9 M dont 9146 distinctes
- 1 à 35 par protéine → multi-label


↓
Fonctions ?

Construction des graphes de similarité

Graphe BLAST



Graphe Embeddings



Métriques d'évaluation de prédiction



80% d'annotations
d'entraînement

20% d'annotations
de test

$$F1 = 2 \cdot \frac{(\text{précision} \cdot \text{rappel})}{(\text{précision} + \text{rappel})}$$

précision

$$\frac{\text{nb de protéines correctement attribuées à l'annotation a}}{\text{nb de protéines totales attribuées à l'annotation a}}$$

rappel

$$\frac{\text{nb de protéines correctement attribuées à l'annotation a}}{\text{nb de protéines possédant vraiment l'annotation a}}$$

Standard d'annotation fonctionnelle : le kNN

Inconvénients du kNN

- Complexité temporelle : $O(M \times V \times \log(V))$
avec :
 - M : nombre de protéines à annoter
 - V : degré de la protéine à annoter
 - $\log(V)$: coût du tri des voisins
- Trop coûteux à grande échelle
- Sensible aux valeurs aberrantes
- Ne peut voir que le connu

Résultats - tests effectués sur $k = \{3, 5, 7, 11\}$

- Validation topologique de BLAST
 - **Précision** : de 87,3 % à **87,1 %**
 - **Rappel** : de 90,5 % à **93,2 %**
 - Meilleur k : **$k = 11$** avec un **F1-score** de **90,0 %**

Algorithmes de Clustering

MCL

(Markov Clustering
aLgorithm)

Principe : marche aléatoire sur le graphe

Complexité : $O(n^3)$

Paramètres : - **Puissance e**

contrôle l'expansion
de la matrice

- **Inflation r**

contrôle la granularité
des clusters

Leiden

Principe : optimisation de la modularité

Complexité : $O(n \log(n))$

Paramètres : - **Résolution gamma**

contrôle la granularité
des clusters

Métriques d'évaluation des clusters

Cohérence structurelle

Co-distance :


- mesure d'homogénéité
- intra-cluster
- points proches entre eux au sein du cluster
- $[0, +\infty]$
- à minimiser

$$\text{codist}(P) = \sum_{k=1}^K \sum_{\{x, x'\} \subseteq C_k} d(x, x')$$

Cohérence biologique

Indice de Jaccard :

$$J(A_i, A_j) = \frac{|A_i \cap A_j|}{|A_i \cup A_j|}$$



Méthode de propagation des annotations

Annotations à propager au sein d'un même cluster

1. Lister les annotations majoritaires : celles dont la proportion dépasse 30% des annotations du cluster
2. Repérage des paires incompatibles
3. Si les annotations **A** et **B** sont incompatibles :
 - a. $\%(A) > \%(B)$: garder **A**, supprimer **B**
 - b. $\%(B) > \%(A)$: garder **B**, supprimer **A**
 - c. $\%(A) = \%(B)$: par sécurité, on supprime les deux

Méthode de propagation des annotations


Seuil de propagation choisi : 0,7

Différents cas de la propagation d'annotations majoritaires

Prenons une protéine **P1** à propager à **P2**

A et **B** sont des annotations majoritaires

1. **P1** et **P2** ont des annotations **100% compatibles**
 - a. **Union** des annotations de **P1** et **P2**
2. **Incompatibilité entre deux annotations** de **P1** et **P2**
 - a. Pas de propagation



03

Première Approche

1 - Combinaison linéaire pondérée

- graphe de similarité **BLAST**
- graphe de la similarité cosinus des **embeddings**

$\text{poids} = \alpha \times S_{\text{BLAST}} + (1 - \alpha) \times S_{\text{embed}}$ avec $\alpha \in [0, 1]$

2 - Clustering avec **MCL** et **Leiden**

Recherche des meilleurs paramètres des algorithmes de clustering et du meilleur alpha

$r \in \{1.5, 2.0, 3.0\}$ $\gamma \in \{0.1, 0.5, 1.0, 2.0, 5.0\}$ $\alpha \in \{0.0, 0.2, 0.4, 0.6, 0.8, 1.0\}$

3 - Calcul et analyse des métriques de clustering pour juger de la qualité de la partition obtenue (la co-distance pour l'homogénéité et la coupe normalisée pour la séparabilité)

4 - Propagation des annotations au sein de la partition


5 - Calcul et analyse des mesures de la qualité de la prédiction des annotations (f1-score, rappel, précision)

Résultats du Clustering


MCL

 $\alpha = 0,5$

Leiden





Fragmentation du graphe en petits clusters




Identification des larges clusters

Résultats du Clustering


MCL $\alpha = 0,5$ **Leiden**

Complexité temporelle en pratique

Temps d'exécution MCL en fonction de la taille de la composante



Temps d'exécution de Leiden en fonction de la taille de la composante




Complexité Théorique :


$O(n^3)$

$O(n \log(n))$

Partitions de BLAST et des embeddings



Identification des larges clusters



Fragmentation du graphe en petits clusters

Évaluation de la propagation après fusion BLAST / embeddings

Meilleur résultat

MCL ($\alpha = 0.2$)

→ F1 = **47.2 %**

⇒ **Embeddings** permettent
gain +11 points de F1

Couverture = 36.3 %


Précision = 90.2 %

Rappel = 31.9 %

BLAST seul

MCL ($\alpha = 1.0$)

→ F1 = **36.0 %**



04

Deuxième Approche

1 - Clustering avec Leiden et $\gamma = 1,0$

- graphe de similarité **BLAST**
- graphe de la similarité cosinus des **embeddings**

2 - Combinaison des deux partitions obtenues

Boucle principale

- a** - Propagation des annotations dans la partition de BLAST
- b** - Pour toute protéine, reporter son annotation dans BLAST aux **embeddings**
- c** - Propagation des annotations dans la partition des embeddings
- d** - Pour toute protéine, reporter son annotation dans les **embeddings** à BLAST

3 - Condition d'arrêt : pas de nouvelle annotation ajoutée à BLAST ou aux **embeddings** à la fin d'une itération


Fusion finale des partitions après convergence

Différents cas de la propagation pour la prédiction finale

Prenons une protéine P1, écrite **P1B** sur **BLAST** et P2E sur les embeddings

1. **P1B** et P2E ont des annotations **100% compatibles**
 - a. **Union** des annotations de **P1B** et P2E
2. **Incompatibilité entre deux annotations de P1B et P2E**
Quelles annotations choisir ?
 - a. Comparaison de l'adhérence locale de la protéine dans chacun de ses clusters
 - b. Le cluster où elle a le plus grand score l'emporte
 - i. Si $S_B = S_E$, protéine déclarée indéterminée

2. A et C incompatibles



Évaluation de la co-propagation d'annotations

Approche	Méthode	Couverture	Précision micro	Rappel micro	F1 micro
Approche 1	Leiden, $\alpha = 0.0$, $\gamma = 1.0$	39.09%	80.46%	28.72%	42.33%
Approche 1	MCL, $\alpha = 0.2$, $r = 2.0$	36.34%	90.19%	31.94%	47.17%
Approche 2	Co-propagation BLAST / embeddings	42.01%	75.32%	30.42%	43.34%

Approche 1 - Fusion avant clustering

1 seul graphe combinant BLAST + embeddings

- **F1** meilleur: **47.2 %**
- **Précision** élevée : **90.2 %**
- Meilleur **compromis** global

Approche 2 - Partitions séparées puis co-propagation

BLAST et embeddings séparés, annotations circulent

- Meilleure **couverture** : **42.0 %**
- Exploitation séparée des 2 sources
- Proposition de + de **candidats**

05

Conclusion

01

Préparation des données

- Extraction des annotations PFAM
- Construction des embeddings
- Séparation train/test pour évaluer la prédiction

02

Construction des graphes

- Graphe BLAST : similarité par alignement
- Graphe embeddings : similarité cosinus
- Graphe hybride : combinaison pondérée BLAST / embeddings

03


Étude du clustering

- Comparaison de MCL et Leiden
- Réglage des paramètres : inflation r , résolution γ , poids α
- Analyse de la fragmentation, de la co-distance et du temps de calcul

04

Évaluation biologique et prédictive

- Cohérence clusters / PFAM
- Propagation d'annotations
- Comparaison précision/rappel/F1, couverture



06

Ouverture

- **Intégration de la structure 3D protéines** (obtenue avec AlphaFold)
 - Annotation de protéines ayant divergé en séquence mais conservant un repliement identique
- **Étude plus approfondie sur l'influence des dimensions de la séquence sur l'annotation de la protéine**
- **Analyse plus poussée sur l'incompatibilité des annotations au niveau biologique**



Avez-vous des questions ?

CREDITS: This presentation template was created by **Slidesgo**, including icons by **Flaticon**, and infographics & images by **Freepik**

Please keep this slide for attribution

**Slides
supplémentaires
pour les
questions**

Embeddings : utilisation de ProteinBERT

- Construction des **vecteurs** sur les **séquences d'acides aminés** des protéines
 - Deux protéines ayant la même fonction auront des embeddings similaires

ProteinBERT

- Entraîné sur **106 millions de protéines** (ensembles des protéines connues) sur les tâches :
 - modélisation bidirectionnelle du langage naturel des séquences protéiques
 - prédiction des annotations Gene Ontology (GO)
- Production de vecteurs de **15 530 dimensions**

Réduction de dimension grâce au PCA

- **IncrementalPCA** : apprentissage sur les 50 000 premières protéines
- Nouvelle dimension : **512**
- **98,20%** de l'information dans les **10 premières composantes**

Fonctionnement de Leiden

Amélioration directe de l'algorithme de **Louvain**.
-> Identification des communautés intérieurement mal connectées

Louvain


Algorithme non supervisé

- Basé sur l'**optimisation de la modularité**
- Efficace sur des **graphes de grande taille**
- Complexité temporelle théorique : $O(n^2)$

Modularité (Q) : score qui mesure si le découpage d'un réseau en clusters est « meilleur que le hasard »

- $Q \approx 0$: le clustering n'est pas mieux qu'un tirage au sort
- $Q \approx 1$: communautés denses et bien séparées

Leiden



Fonctionnement de MCL

Simulation de marche aléatoire sur le graphe

Paramètres

- **Expansion e :**
 - Généralement, $e = 2$
- **Inflation r :**
 - Généralement, $r = 2$
 - Influe la granularité des clusters

Étapes

1. **Phase d'expansion**
 - a. Transformation du graphe en matrice de transition
 - b. Expansion de la matrice de transition (élévation à une puissance e)
2. **Phase d'inflation** (renforcement des probabilités fortes)
 - a. Application d'une puissance r à chaque élément de la matrice
 - b. Normalisation des colonnes
3. **Itération et convergence**
4. **Chaque composante connexe restante forme un cluster**

Stockage des incompatibilités

⇒ sur 2 niveaux

Stockage des compatibilités entre annotations Afin de faciliter le calcul des incompatibilités entre protéines, nous avons d'abord étudié les cooccurrences entre annotations PFAM. Deux annotations sont considérées comme compatibles si elles apparaissent ensemble dans au moins une même protéine. À l'inverse, deux annotations sont considérées comme incompatibles si elles n'ont jamais été observées ensemble dans une même protéine. Cette structure est utilisée notamment pour vérifier rapidement si deux ensembles d'annotations peuvent être fusionnés sans introduire d'association jamais observée dans les données.

Sur les 9 146 annotations PFAM distinctes, il existe :

$$\frac{9146 \times 9145}{2} = 41\,820\,085$$

paires possibles d'annotations. Parmi celles-ci, seules 62 294 paires sont effectivement observées ensemble dans au moins une protéine, soit environ 0.15% des paires possibles. Les paires non observées représentent donc 99.85% de l'espace des paires.

Type de paire d'annotations	Nombre
Paires possibles	41 820 085
Paires compatibles observées	62 294
Paires non observées	41 757 791
Proportion de paires compatibles	0.15%
Proportion de paires non observées	99.85%

TABLE 4 – Cooccurrences observées entre annotations PFAM.

Cette forte sparsité justifie de stocker les paires compatibles plutôt que les paires incompatibles. En effet, stocker explicitement les incompatibilités reviendrait à conserver presque toutes les paires possibles, ce qui serait inutilement coûteux. En pratique, nous construisons donc un dictionnaire des compatibilités observées :

`compatible[label] = {annotations observées avec label}`.

Deux annotations sont ensuite considérées comme incompatibles si elles sont différentes et si elles ne sont pas présentes dans ce dictionnaire de compatibilité.

Cette définition doit cependant être interprétée avec prudence : une absence de cooccurrence dans les données ne signifie pas nécessairement une incompatibilité biologique absolue. Elle indique seulement que cette association n'a pas été observée dans notre jeu de données. Nous utilisons donc cette notion comme un critère opérationnel pour repérer des clusters potentiellement hétérogènes, et non comme une vérité biologique définitive.